

Variational Autoencoder & Generative Adversarial Network

2025. 6. 11.

Jaehoon Lee


Seoul National University
Data Science and AI Laboratory



DSAIL
Data Science & AI Laboratory

Generative Models


- What are generative models?



- Training dataset으로부터 data distribution을 학습
- 학습이 완료된 모델의 distribution으로부터 data sampling


Generative Models

- Taxonomy of Generative models




Variational Autoencoder

- VAE
 - 확률 모델링을 이용한 생성모델의 전통 강자




Autoencoder

- AE
 - 압축/복원의 과정을 통해 data로부터 저차원의 feature를 unsupervised로 학습하는 방식
 - Encoder
 - Decoder
 - Reconstruction training




Autoencoder

- AE
 - 압축/복원의 과정을 통해 data로부터 저차원의 feature를 unsupervised로 학습하는 방식
 - Encoder : data로부터 저차원의 feature를 추출
 - Decoder
 - Reconstruction training




Autoencoder

- AE
 - 압축/복원의 과정을 통해 data로부터 저차원의 feature를 unsupervised로 학습하는 방식
 - Encoder : data로부터 저차원의 feature를 추출
 - Decoder : 저차원의 feature로부터 다시 data를 복원
 - Reconstruction training



Autoencoder

- AE
 - 압축/복원의 과정을 통해 data로부터 저차원의 feature를 **unsupervised로 학습**하는 방식
 - Encoder : data로부터 저차원의 feature를 추출
 - Decoder : 저차원의 feature로부터 다시 data를 복원
 - Reconstruction training $\|x - \hat{x}\|^2$




Autoencoder

- AE
 - 압축/복원의 과정을 통해 data로부터 저차원의 feature를 unsupervised로 학습하는 방식
 - Encoder : data로부터 저차원의 feature를 추출
 - Decoder : 저차원의 feature로부터 다시 data를 복원
 - Reconstruction training $\|x - \hat{x}\|^2$



Decoder가 복원 가능하다
= Data의 의미있는 요소들을
압축적으로 잘 담고 있음

Data의 유용한 정보들을
함축적으로 잘 담고 있는
feature





Autoencoder

- AE
 - Data를 효율적이고 좋은 feature로 압축가능한 encoder를 다양하게 활용가능
 - Dimension reduction
 - Supervised model의 초기화



Variational Autoencoder



- VAE
 - Autoencoder를 생성모델로 활용하기 위한 방법론
 - Latent space상의 적절한 z 를 decoder의 input으로 사용하여 data를 만들어내고 싶음
 - 그러나 임의의 z 를 decoder의 input으로 사용한다면 의미없는 sample을 만들어내게 됨
 - Why? 임의의 z 는 decoder가 학습된 latent space distribution에 있지 않기 때문



Variational Autoencoder

- VAE


- Autoencoder가 학습된 latent space는 굉장히 복잡하게 모델링 되어있음




Variational Autoencoder

- VAE


- Autoencoder가 학습된 latent space는 굉장히 복잡하게 모델링 되어있음
- 임의의 단순한 distribution에서 sampling한 z 로부터 이미지가 생성되길 기대하는 것은 욕심!
모래사장에서 바늘찾기
- 특히 latent space의 차원이 높아질 수록 자유도가 높아져 latent distribution이 복잡해짐



Numbers generated from latent variable values at sites of the square lattice inscribed in the red disk





Numbers generated from latent variable values at sites of the square lattice inscribed in the red disk





Variational Autoencoder

- VAE
 - Autoencoder가 학습된 latent space는 굉장히 복잡하게 모델링 되어있음
 - Decoder가 복원할 수 있는 z (학습된 latent distribution의 z)가 sampling이 가능해지도록 만든다면?
 - Decoder를 이용한 data 생성이 가능해짐!





Variational Autoencoder

- VAE
 - Autoencoder가 학습된 latent space는 굉장히 복잡하게 모델링 되어있음
 - Decoder가 복원할 수 있는 z (학습된 latent distribution의 z)가 sampling이 가능해지도록 만든다면?
 - 학습된 latent의 distribution을 추가적인 생성모델로 생성하도록 학습
 - 처음부터 latent의 distribution이 sampling하기 쉬운 distribution이 되도록 제약을 걸어줌





Variational Autoencoder

- VAE
 - Autoencoder가 학습된 latent space는 굉장히 복잡하게 모델링 되어있음
 - Decoder가 복원할 수 있는 z (학습된 latent distribution의 z)가 sampling이 가능해지도록 만든다면?
 - 학습된 latent의 distribution을 추가적인 생성모델로 생성하도록 학습
→ 생성모델로 latent를 생성한 다음 이를 decoder의 input으로 해서 최종적으로 data 생성
 - 처음부터 latent의 distribution이 sampling하기 쉬운 distribution이 되도록 제약을 걸어줌




Variational Autoencoder

- VAE
 - Autoencoder가 학습된 latent space는 굉장히 복잡하게 모델링 되어있음
 - Decoder가 복원할 수 있는 z (학습된 latent distribution의 z)가 sampling이 가능해지도록 만든다면?
 - 학습된 latent의 distribution을 추가적인 생성모델로 생성하도록 학습
→ 생성모델로 latent를 생성한 다음 이를 decoder의 input으로 해서 최종적으로 data 생성
 - 처음부터 latent의 distribution이 sampling하기 쉬운 distribution이 되도록 제약을 걸어줌
→ Sampling이 쉬운 distribution에서 뽑은 latent를 decoder의 input으로 하여 최종적으로 data 생성



Variational Autoencoder


- VAE
 - Probabilistic autoencoder를 학습하면서 latent distribution이 sampling하기 쉬운 distribution이 되도록
 - Latent distribution
 - Reparameterization trick
 - Reconstruction loss
 - KL Divergence Regularization




Variational Autoencoder

- VAE

- **Probabilistic autoencoder**를 학습하면서 latent distribution이 sampling하기 쉬운 distribution이 되도록
- Latent distribution : latent 대신 주어진 data에 대한 Gaussian distribution을 latent distribution으로 모델링
- Reparameterization trick : distribution에서 sampling한 latent를 사용해도 gradient가 흐르도록
- Reconstruction loss
- KL Divergence Regularization




Reparameterized




Variational Autoencoder

- VAE

- Probabilistic autoencoder를 학습하면서 latent distribution이 sampling하기 쉬운 distribution이 되도록
- Latent distribution : latent 대신 주어진 data에 대한 Gaussian distribution을 latent distribution으로 모델링
- Reparameterization trick : distribution에서 sampling한 latent를 사용해도 gradient가 흐르도록
- Reconstruction loss $-E_{z \sim q(z|x)}[\log p(x|z)] = \|x - \hat{x}\|_2^2$
- KL Divergence Regularization




Reparametrized




Variational Autoencoder

- VAE

- Probabilistic autoencoder를 학습하면서 **latent distribution**이 **sampling**하기 쉬운 **distribution**이 되도록
- Latent distribution : latent 대신 주어진 data에 대한 Gaussian distribution을 latent distribution으로 모델링
- Reparameterization trick : distribution에서 sampling한 latent를 사용해도 gradient가 흐르도록
- Reconstruction loss $-E_{z \sim q(z|x)} [\log p(x|z)] = \|x - \hat{x}\|_2^2$
- KL Divergence Regularization $D_{KL}(q(z|x) || p(z)) = \frac{1}{2} \sum_{i=1} (\sigma_i^2 + \mu_i^2 - \ln(\sigma_i^2) - 1)$



Reparametrized




Variational Autoencoder

- VAE


- Autoencoder를 학습하면서 latent distribution이 sampling하기 쉬운 gaussian distribution이 되도록
- Latent distribution : latent 대신 주어진 data에 대한 Gaussian distribution을 latent distribution으로 모델링
- Reparameterization trick : distribution에서 sampling한 latent를 사용해도 gradient가 흐르도록

- Reconstruction loss $-E_{z \sim q(z|x)} [\log p(x|z)] = \|x - \hat{x}\|_2^2$

- KL Divergence Regularization $D_{KL}(q(z|x)||p(z)) = \frac{1}{2} \sum_{i=1} (\sigma_i^2 + \mu_i^2 - \ln(\sigma_i^2) - 1)$



Reparametrized



**Z from Gaussian distribution
= decoder가 학습된 영역이라
올바른 image 생성 가능**


Autoencoder

- [실습1] MNIST를 이용한 VAE 학습
 - 1. VAE.ipynb
 - ToDo
 - VAE (encoder, decoder, reparameterization. trick) 구현
 - ELBO loss 구현 (Reconstruction loss 및 KL divergence loss)
 - VAE 학습 및 생성 성능 확인
 - Latent 분석

Generative Adversarial Networks


- GAN

- 한 시대를 풍미한 생성모델의 과거의 최강자




Generative Adversarial Networks

- GAN
 - 경찰과 위조지폐범의 경쟁에 비유
 - 위조지폐범: 위조지폐를 만들어냄
 - 경찰: 위조지폐범이 만든 지폐와 진짜 지폐를 가지고 비교해서 잡아냄
 - 위조지폐범: 경찰한테 안 걸리기 위해 더 좋은 위조지폐를 만들어냄




Generative Adversarial Networks

- GAN
 - 두 network의 적대적 학습을 통한 데이터 생성 학습
 - Generator
 - Discriminator
 - Adversarial Training




Generative Adversarial Networks

- GAN
 - 두 network의 적대적 학습을 통한 데이터 생성 학습
 - Generator = random noise z 로부터 sample을 직접 생성
 - Discriminator
 - Adversarial Training



Generative Adversarial Networks

- GAN
 - 두 **network**의 적대적 학습을 통한 데이터 생성 학습
 - Generator = random noise z 로부터 sample을 직접 생성
 - Discriminator = generator가 생성한 sample과 real data sample을 구별
 - Adversarial Training



Generative Adversarial Networks


- GAN

- 두 network의 **적대적 학습**을 통한 데이터 생성 학습

- Generator = random noise z 로부터 sample을 직접 생성

- Discriminator = generator가 생성한 sample과 real data sample을 구별

- Adversarial Training
$$\min_{\theta_g} \max_{\theta_d} [\mathbb{E}_{x \sim p_{\text{data}}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log (1 - D_{\theta_d}(G_{\theta_g}(z)))]$$

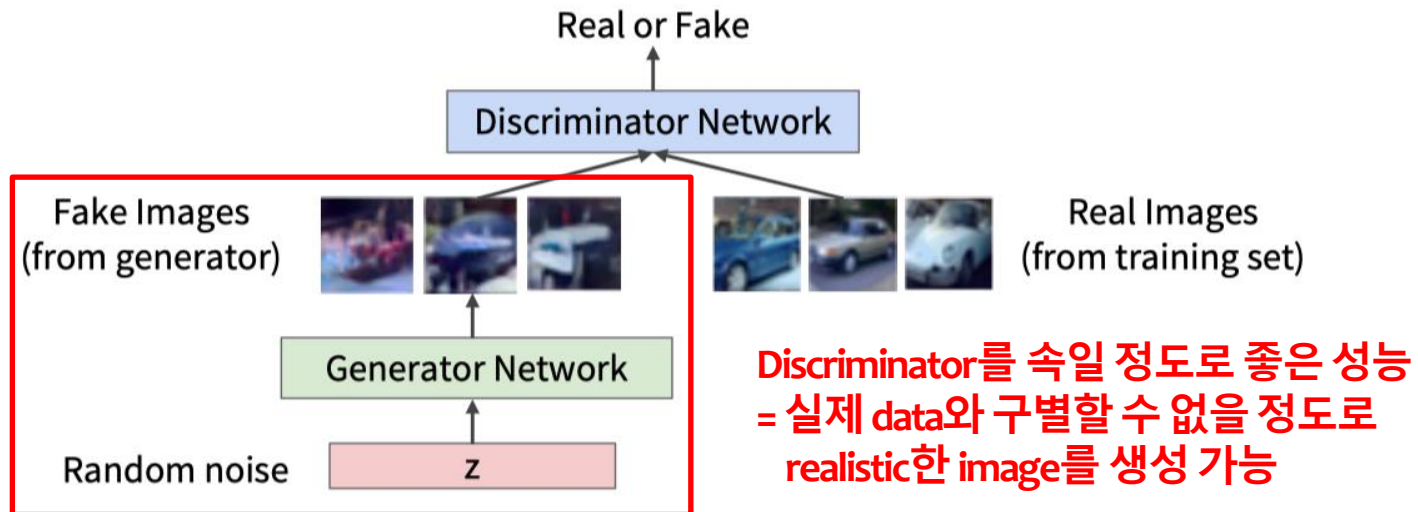


Generative Adversarial Networks

- GAN


- 두 network의 적대적 학습을 통한 데이터 생성 학습
- Generator = random noise z 로부터 sample을 직접 생성
- Discriminator = generator가 생성한 sample과 real data sample을 구별

- Adversarial Training
$$\min_{\theta_g} \max_{\theta_d} [\mathbb{E}_{x \sim p_{\text{data}}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log (1 - D_{\theta_d}(G_{\theta_g}(z)))]$$




Deep Convolutional Generative Adversarial Networks

- DCGAN
 - 새로운 GAN architecture를 제안
 - Convolution layer를 이용해 두 network 구성



Generator



Discriminator

Deep Convolutional Generative Adversarial Networks

- [실습2-1] DCGAN을 이용한 MNIST unconditional generation 학습
 - 2-1. DCGAN-unconditional.ipynb
 - ToDo
 - Generator , Discriminator 구현
 - Adversarial loss 구현
 - Adversarial training 실행

Deep Convolutional Generative Adversarial Networks

- Class Conditional DCGAN

- 기존의 DCGAN은 전체 dataset을 통째로 생성하도록 학습
- Class라는 추가적인 정보를 통해 원하는 데이터를 생성하도록 조절

- Generator = random noise z 로부터 sample을 직접 생성
- Discriminator = generator가 생성한 sample과 real data sample을 구별
- Adversarial Training $\min_{\theta_g} \max_{\theta_d} [\mathbb{E}_{x \sim p_{\text{data}}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log (1 - D_{\theta_d}(G_{\theta_g}(z)))]$



Class label y 추가


- Generator = random noise z 와 주어진 class label y 로부터 sample을 직접 생성
- Discriminator = generator가 생성한 sample과 real data sample을 label y 마다 구별
- Adversarial Training $\min_{\theta_g} \max_{\theta_d} [\mathbb{E}_{x, y \sim p_{\text{data}}} \log D_{\theta_d}(x, y) + \mathbb{E}_{z \sim p(z), y' \sim p_y} \log (1 - D_{\theta_d}(G_{\theta_g}(z, y'), y'))]$



Deep Convolutional Generative Adversarial Networks

- Class Conditional DCGAN

- Generator = random noise z 와 주어진 class label y 로부터 sample을 직접 생성
- Discriminator = generator가 생성한 sample과 real data sample을 label y 마다 구별
- Adversarial Training $\min_{\theta_g} \max_{\theta_d} [\mathbb{E}_{x, y \sim p_{\text{data}}} \log D_{\theta_d}(x, y) + \mathbb{E}_{z \sim p(z), y' \sim p_y} \log (1 - D_{\theta_d}(G_{\theta_g}(z, y'), y'))]$




Deep Convolutional Generative Adversarial Networks

- [실습2-2] DCGAN을 이용한 MNIST conditional generation 학습
 - 2-2. DCGAN-conditional.ipynb
 - ToDo
 - Generator , Discriminator 구현 (conditional)
 - Adversarial loss 구현
 - Adversarial training 실행


A Style-Based Generative Adversarial Networks

- StyleGAN

— Latent vector의 controllability를 극대화한 GAN 계열의 야심작



(b) Style-based generator





Variational Autoencoder

- VAE
 - 궁극적으로 generation process 안에서 training data들의 likelihood를 maximize하는 것
 - 이를 위해 autoencoder의 구조와 함께 복잡한 variational inference를 차용
 - ELBO를 maximize 하도록 학습하게 됨

$$\begin{aligned}\log p(\mathbf{x}) &= \mathbb{E}_{\mathbf{z} \sim q(\mathbf{z}|\mathbf{x})} [\log p(\mathbf{x})] \\&= \mathbb{E}_{\mathbf{z}} \left[\log \frac{p(\mathbf{x}|\mathbf{z})p(\mathbf{z})}{p(\mathbf{z}|\mathbf{x})} \right] \\&= \mathbb{E}_{\mathbf{z}} \left[\log \frac{p(\mathbf{x}|\mathbf{z})p(\mathbf{z})}{p(\mathbf{z}|\mathbf{x})} \frac{q(\mathbf{z}|\mathbf{x})}{q(\mathbf{z}|\mathbf{x})} \right] \\&= \mathbb{E}_{\mathbf{z}} [\log p(\mathbf{x}|\mathbf{z})] - \mathbb{E}_{\mathbf{z}} \left[\log \frac{q(\mathbf{z}|\mathbf{x})}{p(\mathbf{z})} \right] + \mathbb{E}_{\mathbf{z}} \left[\log \frac{q(\mathbf{z}|\mathbf{x})}{p(\mathbf{z}|\mathbf{x})} \right] \\&= \underbrace{\mathbb{E}_{\mathbf{z}} [\log p_{\theta}(\mathbf{x}|\mathbf{z})] - D_{\text{KL}}[q_{\phi}(\mathbf{z}|\mathbf{x}) || p(\mathbf{z})]}_{\text{ELBO: } \mathcal{L}(\mathbf{x}, \theta, \phi)} + \underbrace{D_{\text{KL}}[q_{\phi}(\mathbf{z}|\mathbf{x}) || p(\mathbf{z}|\mathbf{x})]}_{\geq 0 \text{ (intractable)}}\end{aligned}$$

Autoencoder

- [실습1] MNIST를 이용한 VAE 학습
 - 1. VAE.ipynb
 - ToDo
 - VAE (encoder, decoder, reparameterization. trick) 구현
 - ELBO loss 구현 (Reconstruction loss 및 KL divergence loss)
 - VAE 학습 및 생성 성능 확인
 - Latent 분석

Autoencoder

- [실습1] MNIST를 이용한 VAE 학습

- 1.VAE.ipynb

- ToDo

- ELBO loss 구현 (Reconstruction loss 및 KL divergence loss)

$$\log p_{\theta}(x) \geq \mathbf{E}_z [\log p_{\theta}(x | z)] - D_{KL}(q_{\phi}(z | x) || p_{\theta}(z))$$

Autoencoder

- [실습1] MNIST를 이용한 VAE 학습

- 1.VAE.ipynb

- ToDo

- ELBO loss 구현

$$\log p_{\theta}(x) \geq \mathbf{E}_z [\log p_{\theta}(x | z)] - D_{KL}(q_{\phi}(z | x) || p_{\theta}(z))$$

Reconstruction loss

Decoder가 복원한 data distribution 모델링에 따라

1. BCE Loss : data를 Bernoulli distribution으로 보는 경우 사용

$$-E_{z \sim q(z|x)} [\log p(x | z)] = - \sum_{i=1}^N \left[x_i \log(\hat{x}_i) + (1 - x_i) \log(1 - \hat{x}_i) \right]$$

2. L2 Loss : data를 Multi-variate Gaussian distribution으로 보는 경우 사용

$$-E_{z \sim q(z|x)} [\log p(x | z)] = \|x - \hat{x}\|_2^2$$

Autoencoder

- [실습1] MNIST를 이용한 VAE 학습

- 1.VAE.ipynb

- ToDo

- ELBO loss 구현

$$\log p_{\theta}(x) \geq \mathbf{E}_z [\log p_{\theta}(x | z)] - D_{KL}(q_{\phi}(z | x) || p_{\theta}(z))$$

Regularization loss

Z의 prior distribution을 Normal distribution으로 설정

Encoder의 posterior distribution도 Gaussian distribution으로 설정

두 Gaussian distribution의 KL Divergence는 closed-form으로 계산 가능

$$D_{KL}(q(z | x) || p(z)) = \frac{1}{2} \sum_{i=1} (\sigma_i^2 + \mu_i^2 - \ln(\sigma_i^2) - 1)$$

Deep Convolutional Generative Adversarial Networks

- [실습2-1] DCGAN을 이용한 MNIST unconditional generation 학습
 - 2-1. DCGAN-unconditional.ipynb
 - ToDo
 - Generator , Discriminator 구현
 - Adversarial loss 구현
 - Adversarial training 실행

Deep Convolutional Generative Adversarial Networks

- [실습2-1] DCGAN을 이용한 MNIST unconditional generation 학습

- 2-1. DCGAN-unconditional.ipynb

- ToDo

- Adversarial loss 구현

$$\min_{\theta_g} \max_{\theta_d} [\mathbb{E}_{x \sim p_{\text{data}}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log (1 - D_{\theta_d}(G_{\theta_g}(z)))]$$

Discrimnator는 real과 fake를 구별하도록 학습
= real의 label을 1, fake의 label을 0으로 하는 binary classification 학습

$$\max_{\theta_d} [\mathbb{E}_{x \sim p_{\text{data}}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log (1 - D_{\theta_d}(G_{\theta_g}(z)))]$$



BCE loss와 형태 비슷

$$BCE = -\frac{1}{N} \sum_{i=0}^N y_i \cdot \log(\hat{y}_i) + (1 - y_i) \cdot \log(1 - \hat{y}_i)$$



Deep Convolutional Generative Adversarial Networks

- [실습2-1] DCGAN을 이용한 MNIST unconditional generation 학습
 - 2-1. DCGAN-unconditional.ipynb
 - ToDo
 - Adversarial loss 구현

$$\min_{\theta_g} \max_{\theta_d} [\mathbb{E}_{x \sim p_{\text{data}}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log (1 - D_{\theta_d}(G_{\theta_g}(z)))]$$

Generator는 Discriminator를 속이도록 학습
= fake의 label을 0이 나올 확률을 최소화

$$\min_{\theta_g} [\mathbb{E}_{z \sim p(z)} \log (1 - D_{\theta_d}(G_{\theta_g}(z)))]$$



맥락은 비슷

= 대신 fake의 label을 1이 나올 확률을 최대화

$$\max_{\theta_g} [\mathbb{E}_{z \sim p(z), y' \sim p_y} \log (D_{\theta_d}(G_{\theta_g}(z, y'), y'))]$$

$$BCE = -\frac{1}{N} \sum_{i=0}^N y_i \cdot \log(\hat{y}_i) + (1 - y_i) \cdot \log(1 - \hat{y}_i)$$

Deep Convolutional Generative Adversarial Networks

- [실습2-2] DCGAN을 이용한 MNIST conditional generation 학습
 - 2-2. DCGAN-conditional.ipynb
 - ToDo
 - Generator , Discriminator 구현 (conditional)
 - Adversarial loss 구현
 - Adversarial training 실행